



ScienceDirect上可获取目录列表

仿真建模实践与理论

期刊官网 : www.elsevier.com/locate/simpat

混合流水车间仿真优化方法

半导体后端制造中的调度问题 James T.Lin^{*}, Chien-Ming Chen

台湾新竹市光复路二段101号, 国立清华大学, 邮编30013

ARTICLE INFO

ABSTRACT

文章历史记录:

2013年1月29日收到

2014年10月17日收到修订稿, 2014年10月20日接受

2014年12月19日在线发布

关键词:

模拟优化

遗传算法

最佳计算预算分配混合流水线调度半导体后端制造

本研究针对现实半导体后端组装工厂的混合流水线调度问题, 提出了一种基于仿真的优化方法。该问题的复杂程度由供需特征决定, 其中需求随订单数量、产品类型及交货时间的不同而变化。供应量随柔性制造路线数量的变化而变化, 但在包含特定类型和数量的相同且不相关的并行机器的多线/多阶段生产系统中存在限制。订单通常会被拆分为多个独立作业进行并行处理, 随后合并完成以缩短流程时间。对于每单次应用相同合格机型的拆分作业, 会进行质量与可追溯性编译。目标是通过确定每个订单在各阶段的生产线和机型最优配置, 实现可行的最小流程时间。由于问题的复杂性和随机性, 我们采用了仿真优化方法。该方法包含用于性能评估的仿真模型、运用遗传算法的优化策略, 以及通过最优计算预算分配实现的加速技术。此外, 我们还对不同需求水平、产品组合和批量规模进行了情景分析, 以揭示仿真技术的优势。本研究不仅验证了仿真优化方法在实际应用中的价值, 还为随机混合流水线调度问题的后续研究指明了方向。

©2014 Elsevier B.V. 出版。

1. 介绍

半导体制造流程可分为晶圆制备、探针测试、组装和最终检测四个阶段。后端制造工艺是指晶圆制备(前端工艺)之后的生产环节。本研究的灵感来源于某领先外包半导体组装与测试(OSAT)公司的实际案例, 该公司为集成电路设计公司(无晶圆厂)或集成电路制造商(IDM)提供虚拟工厂服务。OSAT公司采用典型的按订单生产(MTO)和合同制造模式。前端设施在技术层面先进复杂, 而后端设施在物流层面却存在诸多问题[37]。

半导体后端制造通常具有较短的交货周期, 能够吸收前端工艺中交货周期波动的影响。在制定时间表时, 需考虑两个影响因素, 即上市时间

*通讯作者。

电子邮箱: jtlin@ie.nthu.edu.tw (J.T.Lin)。<http://dx.doi.org/10.1016/j.simpat.2014.10.008>

1569-190X/©2014 Elsevier B.V. 出版。

以及库存管控。在产品生命周期的初始阶段,后端组装通过提升利润和减少销售损失为客户提供支持。在成熟阶段,虽然没有实体库存,但通过快速响应仍可降低缺货风险。若交货周期短且稳定,由于库存水平与实际需求保持同步,补货风险相对较低。反之,较长的交货周期则会因库存水平基于预测且存在牛鞭效应而增加风险,潜在的库存持有成本和销售损失都会显著上升。半导体后端制造旨在通过缩短流程时间来降低交货周期。这一目标颇具挑战性,因为生产系统复杂且产能有限,特别是在客户委托生产的MTO(制造外包)和合同制造模式中。即使产能充足,组装工厂也无法在未收到晶圆的情况下启动订单生产。半导体后端制造中的排程问题复杂性源于产品种类繁多、并行设备数量庞大、设备专用性以及生产线上的大量作业[17,30,51]。在运筹学领域,仿真与优化是最常用的两种方法。优化方法通过数学形式的精确流程,在相对严格的假设条件下选择最优解。当无法采用精确流程时,会采用启发式或混合方法来获得近似解。由于严格且确定性的假设,精确解可能无法实际应用。相比之下,传统仿真通过描述生产系统并定义输入、过程和输出来预测系统性能,但缺乏优化能力。仿真技术无需物理实现即可提供多种假设场景。这类问题具有现实意义,其解空间庞大,即便预期需要优化,但直接应用精确解流程来获得最优解仍存在困难。近年来,通过模拟技术实现的离散优化方法已发展成熟,可有效解决具有离散决策变量的随机优化问题。然而,该方法在实际应用中面临两大瓶颈:一是模拟过程耗时过长,二是随机条件下模拟评估结果存在显著波动[27]。要使该方法真正落地,必须攻克这些技术难题。

1.1. 问题陈述

典型的后端组装流程包含多个步骤,如图1所示。首先用胶带固定晶圆表面以防止电路受损(“贴膜”)。接着通过“后磨”工艺减薄晶圆厚度以满足封装技术要求。随后采用薄膜和金属框架进行固定(“贴膜/安装”),之后进行切割并清洗掉边角料(“锯切”)。通过粘合剂将芯片固定在基板或引线框架上(“芯片键合”),再用金线或铜线将芯片与基板或引线框架连接,同时实现芯片与外电路的导通(“引线键合”)。元器件的电路通过模塑工艺进行保护,既能防止外部力量造成损坏,又能增强其物理特性(“模塑”)。接下来是“标记”工序,将芯片从引线框架和引脚上分离,同时形成用于连接芯片的焊球(“修边/成型”或“焊球定位”)。最后一步是“最终目视检查”。完成后,产品将根据客户要求转移至测试设施进行检测[54]。

在组装工厂中通常存在多条生产线。通常以焊线机数量(约500至1000台)作为衡量瓶颈的标准,以此评估管理跨度的效率。其他设备的数量则取决于焊线工序的产量。每个工序包含不同类型的设备,这些设备会与其他类型设备并行配置。这种布局主要基于两个原因:(1)根据产品质量等级或精度要求不同,需要配置不同类型的设备来执行特定工序;(2)不同供应商的设备技术或采购策略不断演变。因此,建立了一个由多个相同且不相关的并行机器组成的多线/多级生产系统。

不同客户需要不同类型的设备,每个客户都会指定一款特定设备。产品工程师通过新产品的引入(NPI)认证流程来创建新产品主数据,或通过工程变更管理(ECM)流程修改现有产品主数据,例如新增已认证的机型。经审批后,产品主数据会分阶段记录生产路线,通过为每个产品单独记录各阶段及反向加工时间,对生产线和机型进行认证。

在MTO(制造外包)环境中,订单源源不断涌入。装配车间通常通过瓶颈工序来安排订单的出货时间。但单靠一个瓶颈工序并不够用,因为生产流程中的柔性路线和实体会通过拆分并行处理,以及合并完成和发货来调整。每天都有大量不同出货时间的订单陆续出货。后端半导体制造的订单通常包含特定要求




图1.典型的半导体后端组装工艺。

合同客户、晶圆批次号、器件型号及数量。当工厂收到订单后，首要步骤是从现有生产线中选定生产线，并为每个生产阶段选择对应的设备类型。由于芯片键合、引线键合和模具成型这三个关键步骤直接决定了后端制造的流程时间，因此本研究将重点聚焦于这三个关键环节。

数量参数用于拆分订单。该参数值代表各生产阶段的作业量。在NPI或ECM工艺中，产品工程师会选定符合标准的基板或引线框架作为芯片载体。每个基板或引线框架包含特定数量的芯片，而每个料盒则装载多条基板或引线框架。料盒作为作业转移的容器，其容量即为拆分订单的参数。该数量通过将每条基板或引线框架中的芯片数量乘以料盒内的条带数量计算得出。

图2展示了生产环境与实体（订单和作业）流程作为生产行为的示例。方案1包含两条各含三个阶段的生产线。每个阶段配备不同型号的设备，数量也各不相同。例如，生产线1配备两种键合机（WB1和WB2）及三台设备，而生产线2仅配备一种键合机（WB2）及四台设备。本例包含三个订单。订单2（大黑点）具有特定产品类型和需求数量，该订单被分配给合格的芯片键合机（如DB1）。图3展示了芯片键合阶段的详细流程，从晶圆中取出芯片到将基板放入料盒。该流程会持续重复，直至满足一个料盒的生产需求。订单被拆分为多个作业（小黑点）用于键合阶段，再次从键合机中选择一种设备类型（如WB1）。作业随后进入料盒内的模具阶段，此时从模具机中选择一种设备类型（如MD1）。因此，所有从订单拆分出的作业都会进行同步并行处理，每个阶段都使用相同类型的机器，最终在完成时进行合并。单个订单的流程时间从订单释放时刻开始计算，直到所有后续作业完成为止。由于存在多个订单和作业，主管在拆分和合并过程中难以有效管理瓶颈转移问题及生产行为。




图2.生产线及任务分配与生产行为示例。




图3.芯片键合阶段的详细流程。

在生产系统中,图2中的方案1和方案2展示了不同生产阶段和订单类型下生产线与设备类型的配置示例。由于加工时间、缓冲区等待时间和设备切换时间存在差异,不同配置方案的生产流程效率会有所不同,特别是在设备在工序间移动时需要更换的情况下。图2仅为示例,实际应用中也可采用其他配置方案。当订单数量增加时,系统复杂度会随之提升。

系统复杂性源于每个订单都存在多种路线选择方案,而这些方案受限于系统容量、生产能力及生产条件。多个订单同时到货,涉及不同设备需求、特定客户、晶圆批次编号及数量。容量限制意味着生产系统中并行机器的数量有限。产能约束规定:每个产品只能在特定合格的生产线和机型上生产,且对应不同的随机加工时间。生产行为条件包含以下要素:(1)生产过程中订单拆分与合并;(2)当机器加工时发生产品变更,会产生序列依赖的准备时间;(3)同一订单的所有工序在每个阶段必须使用相同机型。

本研究聚焦于如何将订单及其后续工序分配到特定生产线和机型,以在满足产能、能力及生产行为条件的前提下实现最短流程时间。该问题可视为混合流水线调度问题(HFSSP)的扩展。但本研究与传统HFSSP研究存在以下差异:(1)从单线扩展到多线,(2)将机器类型从单纯相同或无关的单一设备扩展为不同机型组合,(3)在特定条件下考虑生产行为特征。

本文的其余部分组织如下。第二部分系统梳理了实践与理论领域中同类问题的相关文献。第三部分重点阐述仿真优化方法,同时详细解析仿真建模与优化的具体实施步骤。第四部分通过实证研究展示参数选择依据,对比不同目标视角与技术手段带来的性能差异,并在本节中呈现情景分析。第五部分最终总结全文核心结论。

2. 文献综述

2.1. 半导体后端制造排程问题研究

半导体后端制造中存在若干产能规划与调度特征,这些特征通常分为两类:一类是基于月度或周度预测的需求,另一类是基于现有产能和工具确定产品组合的产能规划。这种分类为产能分配提供了指导。实际订单需求需经过执行层面的产能规划,具体包括以机器分配为核心的排程优化、作业流程时间缩短以及交货日期确定。通常采用数学模型进行需求预测。Sweat提出混合整数线性规划模型,用于解决多工厂环境下产品组合规划与产能分配问题[45]。Wang等人提出基于预测的中期产能规划对齐方案,并建立排程框架以解决后端装配环境中排程与机器分配的偏差问题[50]。Potoradi团队运用基于仿真的排程方法实现需求最大化,通过离散事件仿真技术缩短准备时间并优化批次释放机制来减少延迟。研究还探讨了产品多样性、将键合机作为瓶颈设备组的应用,以及装配车间的子批次并行加工技术。不过目前尚未提出完整的优化方案[36]。

唐等人提出了一种启发式算法,用于将大型系统配置为虚拟生产线设计,以确保生产线平衡与效率;该方法已在简化版后端半导体制造系统中得到验证[46]。Pearn等人等在芯片键合机上采用整数规划技术研究了并行机器调度(PMS),针对产品类型和设置时间等机器能力进行调度。研究表明该问题属于非确定性多项式时间(NP)难题,最终通过启发式算法得以解决[32]。Yang和Shen指出键合工艺是瓶颈环节,提出启发式算法以缩短完成时间[52]。Chua等人开发了基于智能多约束有限容量的批量释放系统,用于研究批量释放机制[15]。这些研究还探讨了大规模产品组合与多重产能约束下的复杂性[29,53]。Jarugumilli团队提出了一种通过折中方案实现半导体后端制造执行级产能分配的框架。

该研究采用混合优化-仿真模型,但仿真仅用于验证可行性,未进行优化[20]。陈等人提出了集成模块,用于无限容量计划系统中的批次放行和交货时间估算,同时考虑了产能与能力属性。研究中提出了多种具有工具配置关系的机器类型,每个产品均根据设备能力进行处理。上述研究包含在制品(WIP)拉动、批次放行、资源选择、工作量积累及工作量平衡模块[13]。

西瓦库马尔和古普塔通过模拟开发出帕累托最优调度技术,用于确定探测流程的工作顺序,并在循环时间与利用率之间实现了权衡[42,43]。魏格特等人则采用基于模拟的启发式方法优化操作序列,该方法综合考虑了循环时间、吞吐量及工期合规性。该研究探讨了仿真方法的局限性及耗时过长的问题,并提出了一种改进方案[51]。克莱姆特与魏格特通过综合考量设备专用性、设备准备时间及加工时间依赖性等复杂因素,开发出混合式探针技术。将这种优化方案应用于产能分配仿真后,通过分析生产行为特征实现了精准排程。经过精确排程与仿真方法的协同优化,设备准备时间和设备切换次数均得到显著降低[22]。

相关文献综述表明,半导体后端制造的复杂性源于产品组合的多样性、瓶颈因素、并行设备及可用布线路径。鉴于其复杂性,近期研究采用单独的仿真方法或将其与启发式算法相结合。

2.2. HFSSP与并行机器

HFSSP中存在两种特定类型的调度问题,即PMS和流水线调度(FSS)。PMS指的是将作业分配到机器上,而FSS指的是作业的顺序。Ribas等人。近期对PMS和FSS领域的已发表论文进行了系统综述,并根据生产系统和解决方案流程对HFSSP问题进行了分类。标准混合流水车间结构如图4所示,该结构包含多个顺序流阶段和至少一个包含多台机器的阶段。每个阶段中的每台机器一次只能处理一个作业。HFSSP的常见假设包括:所有作业和机器在零时刻可用、机器完全相同、准备时间可忽略、不允许作业抢占、缓冲区容量无限以及问题具有确定性。然而现实中这些假设与实际场景或学术关注点存在矛盾,因此后续研究对HFSSP进行了深入分析[38-40]。HFSSP通常是一个NP难且复杂的组合问题,在众多实际场景中普遍存在。具有并行机器和顺序相关准备时间的调度问题难以求解。已知具有顺序相关准备时间的单机调度问题属于NP难问题。

[35].对于并行情形,使用两台相同机器时,最小化作业周期的问题属于NP难问题。

[18].因此,对于具有相同并行机器且具有序列依赖性设置时间的调度问题,其更复杂的最小化作业周期问题同样属于NP难问题[23, 31]。

生产系统在设备类型、作业约束条件和目标设定方面存在差异,其中设备可分为完全相同、统一或无关三种类型。系统复杂性主要源于作业约束条件。非混合型特定约束包括准备时间、加工时间和作业优先级,而混合型特定约束则涉及重新进入、批量调度、批次分割等因素。目标指标可分为在制品、设备利用率、空闲时间、订单完成量、流程时间及库存量。解决方案涵盖精确计算、启发式算法、混合方法或仿真/决策支持系统。启发式算法分为构造性方法和改进程序(即元启发式算法)[38]。孙等人针对大型复杂FSS问题开发了多目标优化算法[44]。查里团队则采用遗传算法(GA)解决需求不确定性下的鲁棒HFSSP问题[7]。乔杜里和德雷克将遗传算法应用于机器调度与工人分配,以最小化总延误时间[9]。陈等人提出了一种基于遗传算法的作业车间调度方案,适用于柔性多产品并行机床钣金作业车间[8]。阿尔梅德和哈特尔采用基于可变邻域搜索的仿真优化方法解决随机柔性流水线问题。相较于确定性精确方法,仿真优化在模拟随机生产行为和细化工艺流程方面更具优势。此外,该方法还能综合考量机床利用率、缓冲区容量及循环时间[1]。




图4.混合流水车间标准结构。

在调度问题中,使用完成时间来衡量性能需遵循通用准则。最小化 F (最大流时间)本质上表明,调度成本直接取决于持续时间最长的任务。最小化 C (最大完成时间)则暗示调度成本与处理系统完成所有任务所需的总时间相关。当准备时间为零时, C 和 F 的数值完全相同。然而当准备时间非零时,这两个变量的差异显著。 F 的数值(the mean flow time) is minimized through $\frac{1}{n} \sum_{j=1}^n F_j$,其中订单 j 的流动时间 F_j 定义为 $F_j = C_j - r_j$ 。该表达式表示订单 j 的完成时间与释放时间之差[16]。 F 的数值源自总流动时间,这可能导致饥饿现象,即某些作业会被无限期延迟。为解决这一局限,研究者还考虑了 $F_{\max}$ 的使用[2]。

过去50年间, HFSSP (生产系统优化模型) 已引发学界广泛关注。由于实际生产系统存在显著差异, 解决方案中需充分考量其独特特性及适用流程。据我们所知, 目前仅有少数研究涉及多工位与群组并行生产系统, 包括同构设备、异构设备, 以及随机环境下特定生产条件的同步考量。此外, 关于模拟优化方法[38]的应用研究也相对有限。

2.3. 仿真优化与计算预算优化

卡森和玛丽亚将仿真优化定义为无需显式评估即可确定最佳输入变量值的过程。图5展示了仿真优化模型, 该模型由仿真与优化循环构成[6]。泰金和萨本丘奥卢指出, 最精确的系统往往极其复杂。这种复杂程度使得性能计算和最优决策变量的分析识别变得困难, 有时甚至无法实现。仿真优化是一种强大的决策工具, 能够捕捉现实世界复杂系统中各实体间的精妙关系与交互作用, 并据此确定最佳设计方案或解决方案[28]。仿真优化问题可分为局部优化和全局优化两类, 其中局部优化技术又根据参数类型进一步细分为离散参数和连续参数两类。全局优化的搜索算法包括进化算法 (EAs)、禁忌搜索、模拟退火、贝叶斯/采样算法以及梯度面法[47]。布兰克和卡特菲尔德曾将进化算法应用于动态调度问题[4], 近期扩展研究则运用进化算法建立最优调度规则[3]。在调度问题中, 遗传算法 (GA) 是最受欢迎且应用最广泛的进化算法之一[33,48]。

随机模拟是分析现代复杂系统的一种强大建模与软件工具, 在物理实现前即可完成分析, 该方法能精准描述具有逻辑复杂性且非代数变量与约束条件的系统[25]。然而, 系统行为的定义源于输入值, 而过程的定义则源于输出值, 这两个因素都至关重要。从业者需要从假设角度理解系统性能和关键因素, 这颇具挑战性, 因为模拟无法得出最优解。模拟优化被视为解决这一问题的替代方案。

模拟优化是指运用蒙特卡洛模拟或离散事件模拟等技术进行的随机优化。然而系统行为本身具有随机性, 需要通过统计学方法进行多次重复实验来测量输出结果, 这种操作会消耗大量模拟资源。根据大数定律, 样本量越大, 从样本中获得的数值就越可能接近总体真实值。许多研究者在规划研究时会以30为样本量目标[19]。当观察到 k 个备选方案时, 我们可获得 $k \times 30$ 次重复实验。陈等人提出了最优计算预算分配 (OCBA) 作为终极模拟资源[11,12]。OCBA是解决选择问题的三大主流方法之一, 另外两种方法分别是无差异区法和信息期望值法[5]。该方法采用统计学原理而非等概率规则。每个被选方案最初需要 n_0 次重复计算来获取初始估计值, 后续步骤则通过比较各方案差异来确定优劣。因此, 模拟资源仅按 $\psi(\psi)$ 次重复计算分配给具有较大方差但表现相近的方案, 直至统计正确选择概率 (PCS或P(CS)) 达到目标值或资源耗尽。OCBA通过在随机系统中最小化重复计算次数[10,12], 充分发挥了模拟优化的优势。施密特等人提出的OCBA与进化算法 (EAs) 结合方案, 旨在大幅减少进化算法在噪声环境中正常运行所需的评估次数[41]。OCBA主要应用于以下两个领域。第一个应用是通过局部优化直接减少复制次数, 从而确定有限集合中的最优解。




图5. 仿真优化模型。

替代方案。第二种应用是与搜索算法的间接集成,该算法在搜索过程中需要反复评估和比较潜在解决方案,以确定后续搜索方向[24]。模拟优化技术持续被应用和开发,用于解决复杂问题[25]。

3. 建议做法

我们研究一个NP难的混合流水线调度问题。决策涉及订单分配到生产线和机器类型的具体条件,包括产品-机器专用、批次拆分与合并等。但同一订单下的作业必须在每个阶段由相同类型的机器处理。由于机器可用性存在随机性,处理时间构成了一个受非闭式约束的随机离散优化问题。针对此类问题,模拟优化是常用的解决方案。鉴于采用了大规模解空间和仿真方法,我们结合基于遗传算法(GA)和粒子群优化(OCBA)的元启发式加速技术,以解决仿真预算和估计误差相关问题。本研究进一步验证了仿真方法的优势。

本节首先定义基础术语,便于理解生产系统。随后引入仿真建模作为评估机制。根据问题目标和遗传算法(GA)选定的优化策略,设计决策变量并将其嵌入仿真模型。最后,通过流程图详细说明仿真优化方法的实施步骤。

3.1. 术语

描述生产布局的基本术语包括生产线、阶段、机器和产品类型、订单属性、工作行为和性能测量。

生产线:指包含生产阶段所需机器类型以完成订单的生产线。生产系统中存在多条生产线。

生产阶段:具有相同工艺功能的阶段。多个并行设备按类型分类。一条生产线包含多个工序。

机器类型:指根据供应商需求或产品精度要求所采用的特定机型。生产线各阶段均配备不同类型的机器。

产品(器械)类型:指特定器械、合格的生产线和机器类型,以及机器可用性由反随机处理时间引起的。

订单:指客户对器械的具体需求、数量以及具体计划发布时间。

作业:作业是从订单中拆分出来的,其数量定义为一个杂志的体积。作业可以并行处理。每个阶段中,同一订单的所有作业只能由同一类型的机器处理。生产过程中不会出现材料短缺。

设置时间:若在指定设备上更换当前订单与下个订单(或作业)之间的产品类型,则需设置该时间。不同生产阶段的设置时间各不相同。

性能评估:在MTO(多任务订单)机制下,所有具有不同交付时间的订单必须在最小流时间(F)内完成;因此,我们采用 F 和 $F_{\max}$ 作为性能评估指标。本研究中,这两个数值均被最小化。

3.2. 模拟建模

本研究采用Plant Simulation(原eM-Plant)软件构建订单与作业处理的生产系统。仿真工具通常具备多项优势:面向对象的仿真设计便于生产系统配置,通用对象(如图标)可描述系统输入、流程、输出(包括物理生产线、缓冲区及流程中心)、订单及实体流,并通过控制规则和数据采集机制记录所需事件(见图6)。面向对象设计允许用户为每个实体(订单与作业)及其关系(作业是订单的衍生结果)、缓冲区或流程中心设置时间、数量、分布等参数属性。这种设计还能简化生产系统的构建流程。仿真工具可呈现详细架构层级,多种预定义功能辅助用户收集统计信息以供后续分析。许多算法无需通过开放函数与其他系统或设计进行集成。Plant Simulation提供“simtalk”功能,因此可将优化设计打包使用。

我们设计并观察了生产布局与运行状态,构建了仿真模型,并根据生产行为定义了流程。该仿真模型的基本步骤包括:识别生产对象、设计架构层级、建立对象间关联关系。系统搭建完成后,我们进行了模型验证与确认,确保仿真模型既准确又适用于实际生产系统。验证工作从技术角度出发,重点检验模型转换是否到位;确认工作则着重于




图6.模拟建模。

基于系统内容，确保模型准确反映生产系统。采用了经验丰富的管理者在实际生产系统中使用过的数据验证方法。

3.3. 决策变量的GA编码

该问题需要做出两个关键决策。第一个决策是将订单分配到生产线，第二个决策是为每个生产阶段的工序分配对应的机器类型。因此，染色体结构被用来表示决策变量。第一个组件是订单分配，例如当收到三个订单时，就会定义三个基因来表示对应的生产线。第二个组件是每个生产阶段和订单的机器分配，例如当工艺路线包含三个阶段时，就会设计三个基因来表示机器分配。图7展示了具体示例并揭示了问题的复杂性。如果每个订单都由1号和2号生产线生产，那么每个订单都允许




图7.GA编码结构。

在每个阶段需选择两种机器类型,因此总共有4096种组合方案($2 \times 2 \times 2 \times 2 \times 2 \times 2 \times 2 \times 2 \times 2 \times 2$)。若订单数量增至100个且包含两种合格机器类型,方案数量将与复杂系统规模相当。采用两点交叉法进行操作,随机选取两个基因作为交叉对象。在能力约束方面,若新方案(染色体)不符合合格生产线和机器类型要求,则保留原始方案。关于变异操作,系统会随机选取若干染色体,从中选择一个基因进行变异。若新方案仍不符合能力约束,则该交叉组合仍保留原始方案。在遗传算法搜索过程中,采用二元选择法生成新种群,通过高级交叉和变异操作持续优化,直至满足预设的优化条件。

3.4. 将遗传算法 (GA) 与进化策略 (OCBA) 相结合的模拟优化方法的步骤

图8的流程图展示了模拟优化的实施步骤,该流程图以文献[26]为参考。其核心理念与进化循环类似,包含评估、选择和繁殖三个阶段[34]。评估环节旨在测算种群中各解决方案的适应度值,选择环节用于筛选优质候选方案,繁殖环节则通过生成新的候选方案种群进行后续评估,直至满足进化循环的条件。本研究采用模拟评估法,通过将解决方案或替代方案输入模拟模型来测量其性能表现。在随机条件下,单次模拟难以确定候选方案,传统方法通常采用30次等量重复。本研究采用OCBA(最小重复次数)策略,通过较少重复次数即可获得优质解决方案。鉴于解决方案空间庞大,遗传算法(GA)被用于生成或复制改进方案以进行后续评估。

在解决方案搜索和模拟重复过程中,两个组件相互作用。第一个组件是遗传算法(GA)流程,第二个是混合整数规划(OCBA)流程。GA负责寻找最优解,而OCBA则通过合理分配仿真资源来区分优质备选方案并生成新种群。GA会随机生成初始种群并进行n次复制以评估性能和运行时间。种群必须符合排程约束条件(生产线和机型),若不符合则需对特定备选方案进行修正。首先评估初始适应度,筛选出优质备选方案,通过交叉和变异操作与修正后的方案共同构建新种群,并重新评估其适应度。OCBA会释放增量资源,对优质备选方案进行排序以优化GA搜索。OCBA通过P{CS}分配有限的仿真资源,在排序过程中始终采用最小化仿真资源的方式进行GA搜索,直至算法终止。错误的备选方案或解决方案(基因编码)需进行修正。OCBA会应用P{CS}或仿真资源...




图8. 模拟优化步骤的流程图。

在有限资源模拟中，终止条件设定为上限T的倍数。遗传算法（GA）作为全局搜索算法，而模拟加速器（OCBA）则负责局部优化。两者循环运行直至满足终止条件。简而言之，GA从全局视角进行搜索，OCBA则从局部视角对种群中的解进行排序筛选。通过减少复制次数，GA与OCBA的协同作用能有效识别最优解，从而避免模拟过程中需要进行大量重复计算的困境。

4. 插图

4.1. 实证研究

本研究采用装配工厂提供的数据集，涵盖工厂布局、产品（设备）配置及订单信息，涉及三条生产线和三个生产阶段。数据包含五类产品（84台设备用于芯片键合阶段）、15类产品（814台设备用于引线键合阶段）、10类产品（47套模具系统用于模具成型阶段）以及60类产品文件。每个产品都包含经过反向质量认证的生产类型和机器型号，其加工时间分布具有随机性。在产品变更过程中，我们还为每个产品定义了相应的设置时间。当前共有105个订单，每个订单都包含特定产品、需求数量及预定启动时间。该仿真模型通过记录订单从到达至完成的全流程时间，综合考量各生产阶段及生产线中不同机器型号的分配与利用率。在应用仿真优化方法时，搜索算法和OCBA技术发挥着关键作用。

由于遗传算法（GA）与解的效率或质量相关，我们重点考察了其参数——交叉率（CR）和变异率（Mr）。随后，考虑到策略与复制减少的关联性，又对变异系数（OCBA）进行了参数设置。每个GA参数均设定了两个取值范围：交叉率取0.6和0.8，变异率取0.1和0.2。方差分析结果详见表1。其中交叉率是评估性能时使用的主要指标，其差异具有统计学显著性。图9展示了F与F_{max}之间的交互作用结果。结果表明，交叉率和变异率的适宜水平分别为0.8和0.1。

为验证复制水平及不同参数设置下的个体效应与交互作用，我们对OCBA参数（即n²、 μ 和P{CS}）进行了测试，为后续优化步骤提供依据。直观来看，参数越大复制次数越多，而OCBA程序中的备择假设保持不变。但本次测试采用的参数组合不同，且由于进化过程的影响，研究设计（即总体中的备择假设）也发生了变化。

表1
F和F_{max}的方差分析。

根源	德语	P值 [*]	
		$\bar{F}$	F_{max}
克	1	0.018 [*]	0.013 [*]
MR	1	0.22	0.198
Cr*mr	1	0.204	0.663
错误	4	—	—
总计	7	—	—

$\bar{F}$: S=7906.29, R-Sq=82.84%, R-Sq (调整 后) = 69.97%。
 F_{max} : S=19136.2, R-Sq=83.61%, R-Sq (调整后) =71.31%。
^{*} $\alpha \leq 0.05$ 。




图9.GA参数F和F_{max}的主要影响。

该实验流程由遗传算法 (GA) 运行了30代。每个参数均设置两个水平： n_0 取10和20，delta取20和50，P{CS}取0.8和0.9。方差分析 (ANOVA)、F值和 $F_{\max}$ 值结果详见表2。F检验结果显示， n_0 、delta、P{CS}及其与P{CS}的交互作用是主要的重复因子。 $F_{\max}$ 检验表明， n_0 、P{CS}及其与P{CS}的交互作用为主要影响因素。F检验对delta的观察结果表明，较大delta值 (50) 导致总重复次数少于较小delta值 (20)，而 $F_{\max}$ 检验显示delta对总重复次数无显著影响。这种现象可能源于进化周期中不同设计的选取，而非单纯由delta参数决定，或其效应可能弱于其他参数。默认设置中，每次迭代的T值为900，这符合每个备择假设最多30次、种群总备择假设30个的设定。如图所示。在第10和11项中， n_0 、 δ 和P{CS}的合适数值分别为10、50和0.8。

本研究提出的模拟优化方法可基于遗传算法 (GA) 和混合整数规划 (OCBA) 的合适参数进行实施。我们采用遗传算法作为优化策略，并将其与混合整数规划 (GA_{OCBA}) 及传统估计方法相结合 (后者对每个解进行30次等量重复计算，记为 GA_{Equal}) 以供进一步比较。进化终止条件设定为：当第30代后，从F和 $F_{\max}$ 性能指标均达到终止条件时停止。基于此，我们通过GAEEqual算法生成了27,000次重复计算 (种群规模 $\times$ 30次重复 $\times$ 30代)。重复次数的差异直观反映了 GA_{OCBA} 与GAEEqual的性能差异，如图12所示。收敛行为趋势图 (图13) 清晰展示了寻找最优解的过程。研究表明，随机性与基因质量对收敛行为具有关键影响，且在不同流量测量条件下， GA_{OCBA} 在进化计算效率上显著优于传统GAEEqual方法。性能提升不能完全归功于OCBA算法，因为使用遗传算法 (GA) 时的搜索算法原理相似。从F的视角来看， GA_{OCBA} 会持续优化到第21代；而从 $F_{\max}$ 的视角则会持续到第24代。因此，当GAEEqual和 GA_{OCBA} 的模拟资源 (时间) 相同时，由于GA与OCBA结合后能在单次基因革命中完成多代运算，同时OCBA显著减少了复制次数，因此能实现性能提升。使用3.3GHz英特尔酷睿i3处理器和3GB内存时， GA_{OCBA} 仅需约25分钟 (在30分钟的允许时间上限内) 即可获得解决方案。

表2
F和 $F_{\max}$ 的重复实验采用方差分析。

根源	德语	P值	
		$\bar{F}$	$F_{\max}$
n_0	1	0.009*	0.01*
希腊字母表第四字母 δ	1	0.042*	0.213
Pc	1	0.02*	0.024*
n_0 *delta	1	0.192	0.812
delta*PCS	1	0.04*	0.105
n_0 *PCS	1	0.097	0.041*
错误	1	-	-
总计	7	-	-

$\bar{F}$: S=166.170, R-Sq=99.98%, R-Sq (调整后) = 99.89%。
 $F_{\max}$: S=162.635, R-Sq=99.98%, R-Sq (调整后) =99.87%。
* a=0.05。




图10.F参数下OCBA参数的主要效应与交互作用。




图11.OCBA参数在 $F_{\max}$ 维度上的主效应与交互作用。图12.GA_{OCBA}与GAEEqual的复制比较。

图13.获得的性能与收敛行为。

表3
不同场景在F和F_{max} 指标下的性能对比。

流速 性能 ^a	当前需求/60产品 类型	1.5 ×需求/60产品 类型	2 ×需求/60产品 类型	当前需求/30产品 类型
$\bar{F}$	405,596	593,892	704,246	347,955
F_{max}	915,027	1,186,420	1,385,449	772,679

^a 在第二秒。




图14.不同场景下的利用率。




图15.同一订单不同批次的性能差异。

4.2. 情景分析

在物料运输组织（MTO）和合同制造领域，从业者普遍关注不同需求水平与产品组合下设备利用率与生产周期时间的关联性。如表3所示，随着需求量增加，生产周期时间呈现增长趋势，但当产品组合数量减少时，生产周期时间反而缩短。这种现象源于设备准备时间的节省。图14表明，设备利用率是预测瓶颈并提升风险意识的重要指标。该信息能帮助从业者及时启动ECM系统，释放潜在瓶颈。某些机型保持高利用率，而其他机型保持低利用率，工程师可通过合格的共享加载机触发这些功能。

需要说明的是，作业与订单是分开处理的，且在原始问题中作业数量是固定的。但实际应用中，从业者期望通过调整作业数量来缩短流程时间。通常来说，从业者认为作业数量减少（例如减半）能通过并行处理缩短流程时间。如图15所示，我们通过实例展示了同一订单在不同分割层级（常规、0.5倍和1.5倍）下的表现，并演示了其F值指标。由于不同订单的处理结果存在差异，我们难以确定最佳分割层级——某些订单表现更优，而另一些则更差。这个问题需要结合混合流水线调度问题中的批量流处理进行研究，该问题将分割数量作为缩短流程时间的决策变量[14,21,49]。

5. 结论

半导体后端制造采用批量放行机制进行瓶颈调度,使得出货日期的预测变得简单。然而,这种机制忽略了从生产管理系统层面进行瓶颈调整的可能性,却为优化流程时间留出了空间。对从业者而言,优化过程就像个不透明的黑箱。而从学术角度来说,由于该问题属于NP难范畴且涉及非闭合形式约束的随机离散优化,建立数学模型并实现精确解存在较大难度。本研究采用模拟优化结合遗传算法(GA)和混合整数线性规划(OCBA),在可接受的计算时间内完成优化。该方法能有效将订单最优分配到合适的生产线和设备类型,同时实现最短流程时间。这种创新方案既为经验丰富的从业者提供了助力,也为生产计划人员、制造操作员和客户三方创造了双赢局面。此外,通过开展具有管理启示的多种情景分析,模拟方法的优势得以充分发挥。例如,当需求或产品组合发生变化时,某个案例展示了利用率与流程时间之间的关联,这为后续研究将利用率视为多目标问题提供了可能。另一个案例涉及批量优化,通过合理调整生产批次规模可有效缩短流程时间。这些课题都是HFSSP研究中的延伸方向。该方法还为整合实际生产系统数据、利用模拟优化技术开发决策支持系统提供了契机,这种策略在动态生产环境中具有重要应用价值。

后续研究可采用不同组合的搜索算法与加速技术,在保持仿真优化方法的同时提升解决方案质量。针对具有不同目标(如在制品、延迟率和利用率)的工业应用,可进一步分析并设计具有特定特征或生产行为的多样化生产系统。

致谢

作者感谢审稿人提出的宝贵意见,这些意见对改进本研究具有重要帮助。本研究由台湾地区国家科学委员会(NSC)资助(项目编号:101-2221-E-007-066-MY3)。

参考文献

- [1] C.Almeder, R.F.Hartl, 一种针对有限缓冲区现实世界随机柔性流水线问题的元启发式优化方法,《国际生产经济学杂志》145卷第1期(2013)88–95页。
- [2] C.安布赫尔, M.马斯特罗利,《在线调度以最小化最大流时间:一种最优抢占式算法》,载于《运筹学快报》2005年第33卷第6期,第597–602页。
- [3] J.Branke, C.W.Pickardt, 通过进化搜索寻找复杂问题实例以支持作业车间调度规则的设计,《欧洲运筹学杂志》212(1)(2011)22–32。
- [4] J.Branke, D.C.Mattfeld, 动态调度中的预见性与灵活性,《国际生产研究杂志》43卷第15期(2005)3103–3129页。
- [5] J.Branke, S.E.Chick, C.Schmidt, 选择选择程序,《管理科学》53(12)(2007)1916–1932。
- [6] Y.Carson, A.Maria, 模拟优化:方法与应用,收录于《1997年冬季模拟会议论文集》,1997年,第118–122页。
- [7] T.Chaari, S.Chaabane, T.Loukil, D.Trentesaux, 一种用于鲁棒混合流水线调度的遗传算法,《国际计算机集成制造期刊》24卷第9期(2011)821–833页。
- [8] F.T.S.Chan, K.L.Choy, Bibhushan, 一种基于遗传算法的多产品并行金属板材车间调度系统,《专家系统应用》38卷(2011年)8703–8715页。
- [9] I.A.Chaudhry, P.R.Drake,《基于遗传算法的同构并行机器调度与工人分配问题总延迟最小化研究》,载于《国际先进制造技术杂志》第42卷(2009年),第581–594页。
- [10] 陈崇华、唐诺休、余塞山、林杰,《蒙特卡洛模拟的最优计算预算分配及其在产品中的应用》,《仿真与建模实践理论》第11卷(2003年),第57–74页。
- [11] 陈崇汉、李立华,《随机模拟优化——最优计算预算分配》,世界科学出版社(新加坡),2011年。
- [12] 陈崇华、林杰、余塞山、S-E奇克,《离散事件动态系统》第10卷(2000年)251–270页,关于通过模拟预算分配进一步提升序数优化效率的研究。
- [13] 陈杰成、苏立、孙聪、许明,《集成电路封装厂无限容量规划》,载于《国际生产研究杂志》2010年第48卷第19期,第5729–5748页。
- [14] M.Cheng, N.J.Mukherjee, S.C.Sarin,《批次流式处理综述》,《国际生产研究杂志》51卷(23–24期)(2013年),第7023–7045页。
- [15] T.J.Chua, M.Liu, F.Wang, W.Yan, T.Cai, 一种基于有限容量的智能多约束批量释放系统在半导体后端组装环境中的应用,《Robot.Comput.-Integrated Manuf.》23(2007)326–338。
- [16] S.French,《作业序列与调度:作业车间数学导论》,埃利斯-霍伍德出版社,奇切斯特,1982年。
- [17] Fu M., Askin R., Fowler J., Haghnevis M., Keng N., Pettinato J.S., Zhang M.,《半导体后端操作的批量生产调度》,《IEEE半导体制造汇刊》24卷第2期(2011年),249–260页。
- [18] M.Garey, D.Johnson, 计算机与难解性:NP完全性理论指南, W.H.Freeman, 纽约,1997。
- [19] F.Gravetter, L.A.Forzano, 行为科学的研究方法, Cengage Learn.(2011)。
- [20] S.Jarugumilli, N.Keng, C.Dejong, R.Askin, J.Fowler, 用于装配-测试设施的执行级别容量分配决策框架——基于集成优化-仿真模型,见:2008年冬季仿真会议论文集,2008年,第2292–2297页。
- [21] D.J.Johnson,《缩短制造生产周期时间的框架》,《制造系统杂志》22卷第4期(2003年),第283–298页。
- [22] A.Klemmt, G.Weigert, 一种针对带专用约束的并行机器问题的优化方法:结合仿真与容量规划,载于:冬季仿真会议论文集。冬季仿真会议,2011,第1986–1998页。
- [23] S.A.Kravchenko, F.Werner, 一种用于最小化单位设置平均流时间的启发式算法,《信息处理快报》79(6)(2011)291–296。
- [24] L.H.Lee, C.H.Chen, E.P.Chew, J.Li, N.A.Pujowidianto,《模拟优化问题最优计算预算分配算法综述》,载于《国际运筹学杂志》2010年第7卷第2期,第19–31页。
- [25] L.H.Lee, E.P.Chew, P.I.Frazier, Q.S.Jia, C.H.Chen,《仿真优化及其应用进展》,《IIE Trans.》第45卷第7期(2013年),第683–684页。
- [26] L.H.Lee, E.P.Chew, S.Teng, Y.Chen, 多目标仿真演化算法在飞机备件分配问题中的应用,《欧洲运筹学杂志》189(2008)476–491。

- [27]李杰、萨瓦·A·谢晓,基于仿真的随机离散事件系统离散优化研究:非闭式约束条件下的应用,《IEEE自动控制汇刊》54(12)(2009)2900-2904。
- [28]R.C.林、Y.穆斯塔法、K.S.帕苏帕蒂,《基于数据包络分析与遗传算法的多目标仿真优化:外科服务资源优化应用》,《Omega》第41卷第5期(2013年),881-892页。
- [29]刘伟、蔡天杰、蔡天、王飞勇,《半导体后端制造实用批次放行方法》,载于《生产计划与控制》2005年第16卷第3期,第297-308页。
- [30]L.Monch, J.W.Fowler, S.Dauzere-Peres, S.J.Mason, O.Rose,《半导体制造作业调度中的问题、解决方案及未来挑战综述》,《J.Sched.》14卷(2011年),583-599页。
- [31]D.Nait Tahar, F.Yalaoui, C.Chu, L.Amodeo,一种基于作业拆分与顺序依赖设置时间的同构并行机调度线性规划方法,《国际生产与经济期刊》第99卷第1期(2006年),第63-73页。
- [32]W.L.Pearn, S.H.Chung, C.M.Lai,《在芯片键合机上调度集成电路组装操作》,《IEEE电子封装与制造汇刊》30(2)(2007)97-105。
- [33]C.Perkgoz, A.Azaron, H.Katagiri, K.Kato, M.Sakawa,基于遗传算法的多级装配系统多目标流时间控制问题研究,《欧洲运筹学杂志》180(2007)292-308。
- [34]C.W.Pickardt, T.Hildebrandt, J.Branke, J.Heger, B.Scholz-Reiter,复杂动态调度问题调度规则集的进化生成,《国际生产经济学杂志》145(1)(2013)67-77。
- [35]M.Pinedo,《调度:理论与算法与系统》,Prentice-Hall出版社,新泽西州恩格尔伍德克利夫斯,1995年。
- [36]J.Potoradi, O.S.Boon, S.J.Mason,基于仿真的调度方法在半导体装配厂中实现需求最大化,载于:2002年冬季仿真会议论文集,2002年,第1857-1861页。
- [37]D.Quadt, H.Kuhn,半导体组装中的生产计划,载于:第四届爱琴海国际制造系统分析会议论文集,2003年,第181-189页。
- [38]I.Ribas, R.Leisten, J.M.弗拉米南,《混合流水车间调度问题的综述与分类——基于生产系统及求解流程的视角》,载于《计算机与运筹学研究》第37卷(2010年),第1439-1454页。
- [39]R.Ruiz, F.S.伊雷福格鲁, T.乌林斯,《建模现实的混合柔性流水线调度问题》,《计算机与运筹学》35(4)(2008)1151-1175。
- [40]R.Ruiz, J.A.Vazquez-Rodriguez,混合流水车间调度问题,《欧洲运筹学杂志》205(1)(2010)1-18。
- [41]C.施密特、J.布兰克、S.E.奇克,《将统计排序技术整合到进化算法中》,载于《进化计算的应用》,Springer出版社,柏林-海德堡,2006年,第752-763页。
- [42]A.I.Sivakumar,离散事件仿真在多目标动态调度中的应用,《国际计算机集成制造期刊》14卷第2期(2001)154-167页。
- [43]A.I.Sivakumar, A.K.Gupta,基于联合仿真调度的半导体后端在线多目标帕累托最优动态调度,《IEEE电子封装与制造汇刊》29(2)(2006)99-109。
- [44]严孙、张超、高立、王旭,《流水线车间调度问题的多目标优化算法:综述与展望》,载于《国际先进制造技术杂志》。55(2011)723-739。
- [45]S.Sweat, S.Niu, M.T.Zhang, Z.Zhang, L.Zhang,多芯片产品半导体组装与测试制造中的多工厂产能规划,载于:IEEE国际自动化科学与工程会议,2006年,第247-252页。
- [46]唐宇、周明、邱若谷,《后端半导体制造系统虚拟生产线设计》,《IEEE半导体制造汇刊》2003年第16卷第3期,第543-550页。
- [47]E.Tekin, I.Sabuncuoglu,仿真优化:理论与应用的全面综述,《IIE Trans.》36(2004)1067-1081。
- [48]E.瓦拉达、R.鲁伊斯,《基于序列相关设置时间的无关联并行机调度问题遗传算法》,载于《欧洲运筹学杂志》2011年第211卷第3期,第612-622页。
- [49]J.A.Ventura, S.H.Yoon,一种用于有限容量缓冲区批次流式流水线调度的新遗传算法,《智能制造杂志》24(6)(2013)1185-1196。
- [50]王福勇、蔡天杰、刘伟、蔡天,容量规划与生产调度的集成建模框架,载于:2005年国际控制与自动化会议论文集,第1137-1162页。
- [51]G.Weigert, A.Klemmt, S.《半导体后端设施基于仿真的调度启发式算法设计与验证》,载于《国际生产研究杂志》第47卷第8期(2009年),第2165-2184页。
- [52]T.Yang, Y.A.Shen,一种适用于实际规模动态并行机器调度问题的启发式算法:集成电路引线键合,《Prod.Plan.Control》23(1)(2012)67-78。
- [53]钱欣芳、陈天杰、王飞燕、林明伟、蔡天、杨伟、钟聪、朱杰、林明伟,《基于规则库的启发式有限容量半导体后端组装调度系统》,载于《国际计算机集成制造杂志》2004年第17卷第8期,第733-749页。
- [54]张明涛、牛思、邓帅、张志、李琦、郑立,《全球半导体组装与测试制造中可重构套件的层次化产能规划》,载于《IEEE自动化科学与工程汇刊》2007年第4卷第4期,第543-552页。